多模态大模型神经元重要性与分类方法调研

导师讨论稿
研究对象： LLaVA-1.5-7B、Qwen3.5-2B、Gemma-4-E2B-it 的语言 Decoder FFN 神经元
整理日期： 2026-09-12

1. 结论与待确认选择

“神经元重要性”和“神经元分类”需要分开定义：重要性回答一个神经元是否影响模型响应或正确答案；分类回答它更偏视觉、文本、共享模态还是图文交互。

1.1 重要性计算建议

首轮保留四类互补指标，不强行合成为单一总分：

方法	测量内容	在实验中的角色
有效激活概率与 RMS	响应频率和响应幅度	全量、低成本初筛
Logit Contribution	对目标答案 token 的局部促进或抑制	多模态输出贡献分析
Gradient × Activation	正确答案对神经元的局部敏感性	主任务重要性指标
Zero / Mean Ablation	干预后模型行为是否变化	最终因果验证

推荐顺序是“激活初筛—任务归因排序—因果验证”，但四种分数分别保留，避免把不同含义混入一个不可解释的总分。

1.2 分类方法需要导师选择

方案	核心思想	计算成本	跨模型性	创新性	建议定位
A. LLaVA 四类阈值投票	高激活视觉/文本 token 数量投票	低	较弱	低	文献复现基线
B. 激活概率与选择性熵	比较各模态的稳定激活概率	低	强	中	跨模型泛化主方案
C. 2×2 反事实析因分类	分离视觉主效应、文本主效应和图文交互	约 4 倍	强	高	跨模态机制主方案

建议： 若论文重点是“跨模型、跨数据集泛化”，选择方案 B；若重点是“什么才是真正的跨模态神经元”，选择方案 C。方案 A 无论如何都可以保留为低成本文献基线。

2. 神经元定义与统一符号

对于 gated MLP，语言 Decoder 第 l 层、token 位置 t 的 FFN 中间激活为：

$$g_{l,t} = W^{(l)}_{\text{gate}} h_{l,t}, \qquad u_{l,t} = W^{(l)}_{\text{up}} h_{l,t},$$

$$z_{l,t} = \phi(g_{l,t}) \odot u_{l,t}, \qquad o_{l,t} = W^{(l)}_{\text{down}} z_{l,t}.$$

其中：

- l：Decoder 层编号；
- t：token 位置；
- hl,t：进入 FFN 的隐藏状态；
- ϕ：SiLU、GELU 等激活函数；
- ⊙：逐元素乘法；
- zl,t,j：第 l 层第 j 个 FFN 神经元的激活；
- Wdown,:,j(l)：该神经元写回残差流的输出方向。

实验统一在 `down_proj` 之前记录 zl,t,j。具体激活函数和模块名以各 checkpoint 的实际实现为准。

3. 重要性方法一：有效激活概率与 RMS

3.1 有效激活概率

$$P_{l,j,c} = \frac{1}{N_c} \sum_{(s,t) \in c} \mathbf{1}(|z_{l,s,t,j}| > \tau_{l,j}).$$

其中：

- s：样本编号；
- t：token 位置；
- c：视觉、文本、回答等 token 条件；
- Nc：条件 c 下参与统计的 token 数；
- zl,s,t,j：对应神经元激活；
- τl,j：该神经元的有效激活阈值；
- 1(·)：条件成立取 1，否则取 0。

Pl,j,c 越大，表示该神经元在条件 c 下越经常产生有效响应。

由于 SiLU/GELU 不像 ReLU 那样产生大量精确零，不能直接使用 z>0 作为通用激活定义。建议只使用 calibration set 确定阈值，例如：

$$\tau_{l,j} = Q_{0.95}(|z_{l,j}|),$$

其中 Q0.95 表示该神经元绝对激活值的 95% 分位数。也可以在敏感性分析中比较 90%、95% 和 97% 分位阈值。

3.2 RMS 激活

$$R_{l,j,c} = \sqrt{\frac{1}{N_c} \sum_{(s,t) \in c} z_{l,s,t,j}^2}.$$

RMS 对正负激活均有效，同时反映响应幅度和强激活。它适合在同一个模型、同一层内排序；跨模型比较时应转换为层内百分位或稳健 z-score。

3.3 为什么保留

- 只需要前向传播，可以覆盖全部神经元；
- 同一次 activation collection 可以同时计算概率、RMS、均值和最大值；
- MINER 使用激活概率、均值、最大值及注意力加权激活定位 modality-specific neurons，并强调需要在模态 token 集合内归一化。

3.4 局限

高激活只能说明神经元“响应了”，不能证明模型为了得到正确答案“使用了它”。因此该方法只承担初筛，不独立形成任务重要性或因果结论。

4. 重要性方法二：Logit Contribution

单个神经元对残差流的局部写入为：

$$v_{l,t,j} = z_{l,t,j} W^{(l)}_{\text{down},:,j}.$$

对目标答案 token y，定义该神经元的有符号 logit contribution：

$$C_{l,t,j}(y) = z_{l,t,j} \left\langle W^{(l)}_{\text{down},:,j}, u_y \right\rangle.$$

其中：

- uy：目标 token y 的 unembedding 方向；
- ⟨a,b⟩：向量内积；
- Cl,t,j(y)>0：局部上促进目标 token；
- Cl,t,j(y)<0：局部上抑制目标 token；
- |Cl,t,j(y)|：局部贡献强度。

对包含 R 个 token 的完整标准答案 y1,…,yR，使用 teacher forcing 聚合：

$$I^{\text{logit}}_{l,j} = \frac{1}{R} \sum_{r=1}^{R} \sum_{t} |C_{l,t,j}(y_r)|.$$

4.1 为什么保留

- 同时考虑神经元激活和 `down_proj` 输出方向；
- 能区分促进和抑制作用；
- Finding and Editing Multi-Modal Neurons in Pre-Trained Transformers 使用相近的 activation-output 分解定位多模态神经元，不需要模型梯度。

4.2 局限

这是局部输出分解。后续 LayerNorm、非线性和其他层会继续改变最终预测，因此 C 不能被解释为完整的最终概率贡献，也不能单独建立因果结论。

5. 重要性方法三：Gradient × Activation

将正确答案的目标函数定义为：

$$F(x, y) = \log p(y \mid x).$$

单个 token 上的神经元重要性为：

$$G_{l,t,j} = \left| z_{l,t,j} \frac{\partial F(x,y)}{\partial z_{l,t,j}} \right|.$$

跨样本和 token 聚合：

$$I_{l,j}^{\mathrm{G\times A}} = \frac{1}{N} \sum_{s,t} \left| z_{l,s,t,j} \frac{\partial \log p(y_s \mid x_s)}{\partial z_{l,s,t,j}} \right|.$$

其中：

- $z_{l,s,t,j}$：神经元的实际激活；
- $\partial F/\partial z$：标准答案对该激活的局部敏感度；
- 两者乘积：把该神经元缩放到零时，目标函数变化的一阶近似；
- N：聚合时使用的样本-token 单元数量。

5.1 为什么保留

- 直接面向正确答案，而不只是观察激活；
- 一次前向和反向传播即可计算；
- 可以按视觉 token、文本 token、回答 token 分别聚合；
- 相比多步 Integrated Gradients，更适合三模型、三数据集的全量实验。

5.2 局限

- 它是局部一阶近似；
- 梯度饱和时可能低估重要神经元；
- 分数取决于目标函数，所以实验必须固定为 teacher-forced 标准答案 log-likelihood；
- 需要后续消融检验其行为影响。

6. 重要性方法四：因果消融

6.1 Zero ablation

将目标神经元的 post-gating 激活置零：

$$z_{l,t,j} \leftarrow 0.$$

定义损失增量：

$$I_{l,j}^{\text{zero}} = \mathbb{E}_{(x,y)}\left[\mathcal{L}(f_{-j}(x), y) - \mathcal{L}(f(x), y)\right].$$

其中：

- f：原始模型；
- f−j：神经元 j 被置零后的模型；
- $\mathcal{L}$：标准答案负对数似然；
- Izero>0：删除该神经元使模型损失增加。

6.2 Mean ablation

将神经元替换为 calibration set 上相应条件的平均激活：

$$z_{l,t,j} \leftarrow \bar{z}_{l,j,c}, \qquad \bar{z}_{l,j,c} = \mathbb{E}[z_{l,t,j} \mid c].$$

对应的重要性为：

$$I_{l,j}^{\text{mean}} = \mathbb{E}_{(x,y)}\left[\mathcal{L}(f_{\text{mean}(j)}(x), y) - \mathcal{L}(f(x), y)\right].$$

6.3 为什么保留

消融直接检验改变神经元后模型行为是否变化，是四种方法中最强的因果证据。但它仍受神经元冗余、组合效应以及干预是否离分布影响，因此更适合验证候选集合，而非穷举全部神经元。

6.4 对照要求

每个消融组至少配置：

- 同层、同数量随机神经元；
- 同层、同活动度匹配神经元；
- 同层、同 RMS 或其他通用重要性匹配神经元。

Zero 和 mean ablation 应同时报告；若两者方向一致，结论更稳健。

7. 分类方案 A：LLaVA 四类阈值投票

该方案用于复现 Deciphering Functions of Neurons in Vision-Language Models 的四类神经元识别思路。

7.1 每神经元激活归一化

$$\tilde{z}_{s,t,j} = 10 \cdot \frac{\max(z_{s,t,j}, 0)}{\max_{s',t'} \max(z_{s',t',j}, 0) + \varepsilon}.$$

其中负激活被截为 0，该神经元观察到的最大正激活被映射到 10。

7.2 样本级视觉和文本响应

$$V_{s,j} = \mathbf{1}\left(\sum_{t \in T_s^V} \mathbf{1}(\tilde{z}_{s,t,j} > T_V) > n_V \right),$$

$$T_{s,j} = \mathbf{1}\left(\sum_{t \in T_s^T} \mathbf{1}(\tilde{z}_{s,t,j} > T_T) > n_T \right).$$

其中：

- $\mathrm{TsV}, \mathrm{TsT}$：样本 s 的视觉和文本 token 集合；
- TV, TT：归一化激活阈值；
- nV, nT：至少需要多少个高激活 token；
- 原论文示例设置为 $\mathrm{TV}=2, \mathrm{nV}=4, \mathrm{TT}=3, \mathrm{nT}=2$。

样本级分类为：

$\mathrm{Vs,j}$	$\mathrm{Ts,j}$	类别
1	0	visual
0	1	text
1	1	multimodal
0	0	unknown

7.3 Top-$\mathbf{N}$ 样本投票

在神经元 j 激活最高的 top-N 样本上计算：

$$p_c(j) = \frac{1}{N} \sum_{s \in \mathrm{TopN}(j)} \mathbf{1}(C_{s,j} = c),$$

并定义：

$$C_j = \arg \max_{c \in \{V, T, M, U\}} p_c(j).$$

可增加最低置信度要求 $\max c p_c(j) \geq \gamma$；未达到时标记为 unresolved。

7.4 优点、局限和定位

优点： 已有 VLM 论文直接采用；计算成本低；容易复现和比较。
局限： 阈值来自单模型观察；最大值归一化容易受异常值影响；视觉和文本都激活不一定代表真正图文融合；unknown 的功能含义不明确。
定位： 复现已有分类方法，并检验它能否泛化到三个模型和三个数据集。创新性较弱，但风险最低。

8. 分类方案 B：模态激活概率与选择性熵

该方案借鉴 MINER 的模态 token 分组与重要性汇总，以及 Language-Specific Neurons / LAPE 的条件激活概率熵思想，用于建立跨模型统一分类规则。

8.1 模态激活概率

$$p_V(j) = P(|z_j| > \tau_j \mid V), \qquad p_T(j) = P(|z_j| > \tau_j \mid T).$$

归一化为：

$$q_V = \frac{p_V + \varepsilon}{p_V + p_T + 2\varepsilon}, \qquad q_T = \frac{p_T + \varepsilon}{p_V + p_T + 2\varepsilon}.$$

选择性熵为：

$$H_j = -q_V \log q_V - q_T \log q_T.$$

总体活跃度定义为：

$$A_j = \max(p_V, p_T).$$

其中：

- pV, pT：视觉和文本条件下的有效激活概率；
- qV, qT：归一化模态响应比例；
- Hj：选择性熵，越低表示越偏向某一模态；

- Aj：至少在一种模态下的活动程度。

8.2 分类规则

类别	建议规则
visual	$A_j \geq a_0$ 且 $q_V \geq q_0$
text	$A_j \geq a_0$ 且 $q_T \geq q_0$
multimodal/shared	$p_V \geq a_0$ 且 $p_T \geq a_0$，两者差异不大
inactive	$\max(p_V, p_T) < a_0$
uncertain	没有任何类别达到置信度要求

τ_j, a_0, q_0 均在 calibration set 上，按每个模型、每一层的分位数确定，并在 test set 上冻结。

8.3 优点、局限和定位

优点： 不依赖 LLaVA 固定阈值；只需正常前向传播；方便跨模型、跨层和跨数据集比较；比方案 A 更符合 generalization 研究主题。
局限： 仍属于激活相关性分类；不能区分“对两种模态都响应”和“必须依赖正确图文配对”；需要 calibration set。
定位： 建立能够跨 VLM 架构和数据集统一使用的神经元分类方法。风险和工作量适中。

9. 分类方案 C：2×2 反事实主效应与交互效应

该方案是本调研基于析因实验设计提出的研究性扩展，不是直接复刻某一篇神经元论文。它针对方案 A、B 无法区分 shared response 与真正跨模态交互的问题。

9.1 构造四种输入

条件	图像	文本
x_{11}	正确图像	正确文本
x_{10}	正确图像	无效或错配文本
x_{01}	无效或错配图像	正确文本
x_{00}	无效图像	无效文本

四种输入应尽量保持图像 token 数、文本长度、prompt 模板和答案格式一致。无效图像可以使用空白、patch shuffle 或同类别错配图像，并分别做敏感性分析。

9.2 主效应与交互效应

对每个条件计算神经元分数 sj(x)，例如 RMS 或 Gradient × Activation。定义：

$$M_{V,j} = s_j(x_{11}) - s_j(x_{01}),$$

$$M_{T,j} = s_j(x_{11}) - s_j(x_{10}),$$

$$I_{VT,j} = s_j(x_{11}) - s_j(x_{10}) - s_j(x_{01}) + s_j(x_{00}).$$

其中：

- MV,j：有效视觉信息带来的神经元分数变化；
- MT,j：有效文本信息带来的神经元分数变化；
- IVT,j：正确图文组合超出两个单模态主效应的额外交互。

9.3 分类规则

类别	建议规则
visual-selective	MV 大，MT 和 IVT 小
text-selective	MT 大，MV 和 IVT 小
shared-additive	MV,MT 都大，但 IVT 小
interaction-dependent	IVT 显著且跨样本/seed 稳定
inactive	所有条件下活动度都低
unresolved	效应不稳定或置信区间过宽

“大”和“小”不能凭观察决定，应在 calibration set 上预注册最小实质效应 δV,δT,δI，并在 test set 上使用 bootstrap 置信区间判断。

9.4 优点、局限和定位

优点： 能区分 shared-additive 和 interaction-dependent；对 multimodal neuron 的定义最严格；创新空间最大。
局限： 每个样本需要四种输入；反事实控制设计困难；错配可能引入新的分布偏移；统计分析更复杂。
定位： 研究 VLM 中共享模态神经元与真正图文交互神经元的区别。风险最高，但机制研究价值也最高。

10. 分类后的共同验证：类别特异性消融

类别特异性消融不是第四种分类方案，而是可以附加在 A、B 或 C 后面的验证模块。

设消融某一类候选神经元后，在视觉、文本和跨模态任务上的损失增量为：

$$\Delta_V, \qquad \Delta_T, \qquad \Delta_M.$$

定义视觉、文本和跨模态因果特异性：

$$C_V = \Delta_V - \frac{\Delta_T + \Delta_M}{2},$$

$$C_T = \Delta_T - \frac{\Delta_V + \Delta_M}{2},$$

$$C_M = \Delta_M - \frac{\Delta_V + \Delta_T}{2}.$$

只有当统计分类和相应因果特异性方向一致，并且效应超过同层、同数量、同活动度匹配对照时，才标记为 confirmed visual、confirmed text 或 confirmed multimodal。

11. 建议提交导师确认的三个完整选项

选项 1：文献复现型

方案 A + 类别级成组消融

工作量最低，结论容易与已有 LLaVA 论文对齐；适合优先保证复现，但跨模型阈值合理性和方法创新有限。

选项 2：跨模型泛化型（推荐）

方案 B + 类别特异性消融

使用层内校准的激活概率与选择性熵，在三个模型、三个数据集上统一计算，再通过类别特异性消融确认。它在可实现性、跨模型比较和方法改进之间最平衡。

选项 3：跨模态机制型

方案 C + 类别特异性消融

能够进一步区分共享响应和真正图文交互，研究问题最深入，但反事实构造、计算量和统计复杂度最高。

12. 参考文献与可点击链接

1. Huang et al. MINER: Mining the Underlying Pattern of Modality-Specific Neurons in Multimodal Large Language Models. https://arxiv.org/abs/2410.04819
2. Pan et al. Finding and Editing Multi-Modal Neurons in Pre-Trained Transformers. https://aclanthology.org/2024.findings-acl.60/
3. Xu et al. Deciphering Functions of Neurons in Vision-Language Models. https://arxiv.org/abs/2502.18485
4. Tang et al. Language-Specific Neurons: The Key to Multilingual Capabilities in Large Language Models. https://aclanthology.org/2024.acl-long.309/
5. Sundararajan, Taly, and Yan. Axiomatic Attribution for Deep Networks. https://proceedings.mlr.press/v70/sundararajan17a.html
6. Dai et al. Knowledge Neurons in Pretrained Transformers. https://aclanthology.org/2022.acl-long.581/